

AUTO+ — Partie Machine Learning

Oct 2, 2026 · @ayach merouane

1. Introduction

La partie Machine Learning d'AUTO+ livre trois modèles en service dans l'application : estimation du prix d'un véhicule (A), recommandation de garages (B) et détection de faux avis (C). Chaque modèle va de la donnée brute jusqu'à un écran mobile testé sur iPhone.

Modèle	Problème métier	Type de tâche	Données	Résultat principal
A — Prix véhicule	Combien vaut une voiture d'occasion ?	Régression	Réelles : 101 896 annonces marocaines	Erreur moyenne 11 779 DH (10,8 %), R^2 0,939
B — Recommandation	Quel garage pour ma panne ?	Classification de texte + classement	Réelles (garages, pannes) + simulées (choix des clients)	87,5 % des pannes bien comprises, 93 % de garages pertinents
C — Faux avis	Cet avis est-il authentique ?	Classification binaire	Simulées (2 980 avis)	Précision 100 %, rappel 84 %

Données réelles et simulées. L'application n'a pas encore d'utilisateurs réels : seulement 4 comptes, 1 RDV et aucun avis au lancement de la partie ML. Le modèle A repose donc sur un jeu public, le modèle B sur les garages réels collectés, et les parties qui exigent des historiques d'usage (filtrage collaboratif, faux avis) sur des données simulées. Ces simulations suivent des règles documentées et sont présentées comme des preuves de concept, pas comme des performances réelles.

Démarche commune. Pour chaque modèle : analyse des données, nettoyage, comparaison de plusieurs méthodes dans les mêmes conditions, choix justifié par des mesures, évaluation finale sur un jeu jamais vu, puis mise en service et test dans l'application.

2. Modèle A — Estimation du prix d'un véhicule d'occasion

Le modèle retenu, XGBoost réglé avec Optuna, estime le prix d'une voiture d'occasion avec une erreur moyenne de 11 779 DH (10,8 % du prix) sur 10 556 annonces jamais vues, soit environ deux fois mieux que l'estimation par annonces comparables.

2.1 Données

Le jeu MUCars-2024 (Université Abdelmalek Essaâdi, Mendeley Data, DOI 10.17632/vjrbcb2rrt.2, licence CC BY 4.0) contient 101 896 annonces marocaines de 2024 : marque, modèle, année, kilométrage, boîte, carburant, puissance fiscale, état, origine, première main, ville, équipements et prix.

Le nettoyage applique 10 règles documentées et conserve 70 368 annonces (69 %) :

Règle	Annonces retirées	Justification
Prix manquant	24 421	Pas de valeur cible
Doublons exacts	2 805	Annonces republiées
« Neuf » avec plus de 50 000 km	1 611	Incohérence entre deux champs
Prix hors 15 000 – 1 500 000 DH	1 374	Épaves, acomptes, zéros en trop
Prix aberrant par rapport aux annonces comparables	786	Plus de 2× ou moins de 0,5× la médiane du même modèle et âge
Doublons après normalisation	301	Même annonce, casse différente
Véhicule accidenté ou pour pièces	118	Valeur non comparable
Marque invalide	116	Colonnes décalées au scraping

Deux corrections ne suppriment pas l'annonce. Un kilométrage inférieur à 3 000 km par an sur une voiture de 3 ans ou plus est marqué « inconnu » (16 % des annonces) : ces valeurs faisaient qu'une voiture à 20 000 km valait moins qu'une à 60 000 km. Les 14 villes écrites en arabe sont ramenées à leur nom français.

2.2 Protocole

- Découpage 70 / 15 / 15 (entraînement, validation, test), stratifié sur les déciles de prix, graine fixée. Pas de découpage temporel : toutes les annonces datent de 2024.
- 30 variables ; modèles et villes vus moins de 20 fois regroupés en « autre », appris sur l'entraînement seul pour éviter toute fuite.

- Cible = logarithme du prix, pour qu'une erreur soit relative au prix :

$$\hat{y} = \log(\text{prix}), \text{ puis } \text{prix estim\'e} = e^{\hat{y}}$$

- Mesures en dirhams : MAE (erreur moyenne absolue), MAPE (erreur moyenne en %), R^2 , part des annonces estim\'ees à $\pm 15\%$.


$$MAE = (1/n) \times \sum | \text{prix}_i - \text{prix estim\'e}_i |$$

$$MAPE = (100/n) \times \sum | \text{prix}_i - \text{prix estim\'e}_i | / \text{prix}_i$$

2.3 Comparaison de 5 mod\`eles

XGBoost divise presque par deux l'erreur de l'estimation na\"ive

Erreur moyenne absolue (MAE) sur la validation, en DH : XGBoost fait 45 % de moins que la m\'ediane par groupe



ml/reports/model_a_comparaison.json · validation, 10 555 annonces

Les mod\`eles à base d'arbres dominent : la d\'ecote suit une courbe (forte les premi\`eres ann\'ees) et d\'epend d'interactions (une Mercedes ne perd pas sa valeur comme une Dacia), que la r\'egression lin\'eaire ne repr\'esente pas. CatBoost, sp\'ecialis\'e dans les variables cat\'egorielles, arrive 2e et s'entra\^ne 4 fois plus lentement.

2.4 R\'eglage et mod\`ele final

Optuna a test\'e 40 combinaisons de param\`etres, suivies dans MLflow. Parmi les essais à moins de 0,1 % de la meilleure erreur, le plus l\'eger a \'et\'e retenu : 724 arbres de profondeur 12 au lieu de 1 642, soit un mod\`ele de 42 Mo au lieu de 80 Mo, pour 54 DH d'erreur en plus sur le test.

Mesure (jeu de test)	XGBoost non r\'egl\'e	XGBoost final
MAE	12 657 DH	11 779 DH
MAPE	12,2 %	10,8 %

Mesure (jeu de test)	XGBoost non réglé	XGBoost final
R^2	0,935	0,939
Annonces à ± 15 %	79,5 %	80,9 %

L'erreur varie selon le prix : 6,8 % entre 100 000 et 200 000 DH (le segment le plus fréquent), mais 23,2 % sous 50 000 DH, où le prix dépend surtout de l'état réel du véhicule. Par importance de permutation, l'âge pèse le plus, puis le modèle, la boîte, la marque et le kilométrage.

Chaque estimation est accompagnée d'une fourchette calculée sur les erreurs réelles du test, par tranche de prix : elle contient le prix réel de 80 % des annonces.

2.5 Limites

- Prix demandés dans des annonces, pas des prix de vente ; niveau de prix 2024.
- Précision faible sous 50 000 DH.
- Les plus grosses erreurs révèlent des erreurs de saisie dans les annonces (une Ford EcoSport datée de 1987, alors que le modèle est sorti en 2003).

3. Modèle B — Recommandation de garages

Le modèle B comprend la panne décrite en texte libre dans 87,5 % des cas et propose des garages capables de la traiter dans 93 % des cas, à 2,6 km en moyenne. Exemple : « ça grince quand je freine » → freinage → les garages proches qui font les freins.

3.1 Données

- **50 pannes** réparties en 10 catégories (moteur, freins, électricité, climatisation...), avec symptômes, urgence et coût indicatif.
- **123 garages réels** de Casablanca (Telecontact et OpenStreetMap). Les 100 fiches Telecontact ont été collectées lentement (3 s par page, chemin autorisé par le robots.txt) : **91 garages géolocalisés sur 123**, contre 23 avant.
- **Spécialités** : 99 fiches sur 100 ne portent qu'une description générique. Les spécialités viennent donc de la fiche (1 garage), du nom (18, ex. « Carrosserie Maarif »), ou de l'hypothèse « mécanique générale » (104). La source est enregistrée pour vérifier ces hypothèses sur le terrain.

3.2 Comprendre la panne : multilingual-e5-large

Le modèle pré-entraîné intfloat/multilingual-e5-large transforme une phrase en vecteur de 1024 nombres qui représente son sens. Il n'est pas réentraîné : 50 pannes ne suffiraient pas. La phrase de l'utilisateur est comparée aux 50 pannes par similarité cosinus :

$$\text{sim}(q, p) = (q \cdot p) / (\|q\| \times \|p\|)$$

Chaque catégorie reçoit la similarité de sa panne la plus proche, transformée en probabilité par un softmax à température $T = 0,02$ (les similarités e5 sont très resserrées, entre 0,75 et 0,90) :

$$s_c = \max \text{sim}(q, p) \text{ sur les pannes } p \text{ de la catégorie } c$$

$$P(c) = \exp(s_c / T) / \sum \exp(s_{c'} / T), \text{ avec } T = 0,02$$

Sur 40 requêtes écrites à la main (formulations différentes de la base, fautes et tournures marocaines incluses) :

Méthode	Bonne catégorie en 1er	Bonne catégorie dans le top 3
multilingual-e5-large (retenu)	87,5 %	87,5 %
MiniLM multilingue (modèle précédent)	67,5 %	80,0 %
Recherche par mots-clés	40,0 %	42,5 %

Les 5 erreurs viennent surtout de mots absents de la base de pannes (« plaquettes », « amortisseurs »).

3.3 Score des garages

Seules les catégories crédibles sont gardées (au moins 50 % de la plus probable), puis chaque garage reçoit un score :

$$\text{Score}(g) = 0,4 \times S_{\text{spécialité}} + 0,5 \times S_{\text{distance}} + 0,1 \times S_{\text{note}}$$

$$S_{\text{spécialité}} = (\text{somme des } P^*(c) \text{ des catégories retenues que le garage couvre}) \times \text{confiance}(g)$$

$$S_{\text{distance}} = e^{(-d / 5 \text{ km})}$$

$$S_{\text{note}} = (n \times \bar{x} + 5 \times 3,5) / (5 \times (n + 5)), \text{ avec } n \text{ avis de moyenne } \bar{x}$$

- La confiance vaut 1,0 pour une spécialité confirmée et 0,8 pour l'hypothèse « mécanique générale ».

- La distance d est calculée par la formule de haversine ; un garage sans GPS reçoit 0,2.
- La note est une moyenne bayésienne tirée vers 3,5 tant qu'il y a peu d'avis (120 garages sur 123 n'en ont aucun).

Les poids 0,4 / 0,5 / 0,1 ont été choisis sur une grille de 9 réglages. Avec le réglage initial (0,6 / 0,3 / 0,1), un seul garage — dont la fiche liste les 10 spécialités — sortait 1er dans 100 % des cas, même à 10 km. Une mesure de diversité détecte désormais ce biais automatiquement.

Stratégie (40 requêtes × 5 quartiers)	Garages pertinents dans le top 5	Distance moyenne	Garages différents en 1re place
Hybride, modèle B	93,2 %	2,6 km	14
Spécialité seule	94,0 %	6,1 km	1
Garage le plus proche	52,0 %	0,8 km	5

3.4 Filtrage collaboratif (SVD), démonstration sur données simulées

Le filtrage collaboratif apprend des choix et des notes des clients. La factorisation de matrice SVD (bibliothèque scikit-surprise) prédit la note d'un client u pour un garage i :

$$\hat{r}_{ui} = \mu + b_u + b_i + p_u \cdot q_i$$

Entraînement : minimiser $\sum (r_{ui} - \hat{r}_{ui})^2 + \lambda (b_u^2 + b_i^2 + \|p_u\|^2 + \|q_i\|^2)$

μ est la note moyenne, b_u et b_i les biais du client et du garage, p_u et q_i leurs profils (5 facteurs).

L'application n'ayant pas encore d'historique, 300 clients et 1 507 réparations ont été simulés. Chaque garage y a une qualité cachée, invisible pour la partie contenu.

Paramètres choisis par validation croisée : 5 facteurs, $\lambda = 0,02$. Le score hybride ajoute 1,2 × la note prédite normalisée, poids choisi sur la validation.

Méthode (dernière réparation de 270 clients)	Garage choisi dans le top 5
Popularité	26,3 %
Contenu seul	31,9 %
SVD seul	22,2 %
Hybride contenu + SVD	45,2 %

Le SVD prédit aussi mieux les notes que la moyenne (RMSE 0,675 contre 0,762). Ce résultat démontre le mécanisme ; le SVD n'est pas utilisé en production tant que l'application n'a pas de vrais RDV.

3.5 Limites

- 104 spécialités sur 123 sont une hypothèse : peu de vrais spécialistes (climatisation 1, pneus 2, carrosserie 4).
- 3 garages seulement ont une note ; le critère de note pèse peu pour l'instant.
- La pertinence d'un garage est jugée sur les spécialités en base, pas sur sa qualité réelle.

4. Modèle C — Détection de faux avis

Le système retenu (gradient boosting + règle « avis sur un RDV annulé ») détecte 84 % des faux avis sans masquer aucun avis authentique, sur des données simulées. Le résultat le plus instructif : les modèles appris détectent 100 % des fraudes connues mais 0 % d'une fraude jamais vue.

4.1 Données simulées

L'application n'avait aucun avis. 2 980 avis ont été simulés sur 12 mois et les 123 garages réels, en français et en darija écrite en lettres latines, dont 12,8 % de faux :

Type	Avis	Comportement simulé
Authentique	2 600	Comptes d'âge varié, 75 % après un RDV terminé, notes réalistes
Auto-promotion	114	Le garage se fait mettre 5★ : comptes récents, superlatifs, sans RDV
Dénigrement	110	Un concurrent met 1★ : accusations vagues, comptes récents
Ferme d'avis	111	Rafales de 4 à 8 avis 5★ en moins de 48 h, textes quasi identiques
Sophistiqué	45	Texte concret, note 4★, compte ancien ; uniquement dans le test

Des cas difficiles sont volontairement inclus : vrais avis courts (« Très bien ») ou sans RDV, faux avis de comptes anciens. Découpage temporel : 9 premiers mois pour l'entraînement (dont les 2 derniers pour la validation), 3 derniers pour le test.

4.2 Signaux

12 signaux sont calculés avec la seule information disponible au moment de la publication :

- **Comportement** : âge du compte, RDV terminé ou annulé, avis reçus par le garage dans les 48 h précédentes, écart à la note moyenne du garage, note extrême.
- **Texte** : longueur, points d'exclamation, majuscules, superlatifs ou accusations, détails concrets (prix, pièces, délais), ressemblance avec les avis des 30 derniers jours (TF-IDF sur n-grammes de caractères, robuste à la darija et aux fautes ; ignorée sous 6 mots pour ne pas accuser deux « Très bien »).

4.3 Comparaison de 4 méthodes

Méthode (jeu de test, 803 avis)	Précision	Rappel	F1	Vrais avis masqués	Fraude jamais vue détectée
Règles du planning	58,7 %	57,1 %	0,58	9,6 %	2 %
Isolation Forest (non supervisé)	73,2 %	46,1 %	0,57	4,0 %	16 %
Régression logistique	99,1 %	70,8 %	0,83	0,2 %	0 %
Gradient boosting	100 %	70,8 %	0,83	0 %	0 %
Retenu : gradient boosting + règle RDV annulé	100 %	84,4 %	0,92	0 %	47 %

Précision = part des avis masqués qui sont vraiment faux ; rappel = part des faux avis détectés.

$Précision = VP / (VP + FP)$; $Rappel = VP / (VP + FN)$; $F1 = 2 \times Précision \times Rappel / (Précision + Rappel)$

VP = faux avis détectés, FP = vrais avis masqués à tort, FN = faux avis non détectés.

4.4 Système retenu

- **Gradient boosting** (HistGradientBoosting, scikit-learn, classes pondérées), seuil de décision choisi sur la validation.
- **Règle métier** : un avis sur un RDV annulé est vérifié — on ne note pas un garage où l'on n'est pas allé.
- Un avis signalé est masqué et n'entre pas dans la note du garage jusqu'à la décision d'un administrateur, qui voit les raisons de l'alerte. L'auteur ne les voit pas, pour ne pas aider à contourner la détection.
- Un niveau « à surveiller » (Isolation Forest sur le 1 % d'avis les plus inhabituels) a été testé : 9 avis signalés, aucun faux. Il n'a pas été retenu.


4.5 Limites

- Données simulées : comparaison des méthodes, pas performance réelle ; les vrais avis simulés viennent de 8 modèles de phrases.
- Environ la moitié des faux avis sophistiqués est indiscernable d'un vrai client venu sans RDV dans l'application. Enregistrer l'empreinte de l'appareil aiderait.
- Les décisions des administrateurs (validé / rejeté) serviront d'étiquettes pour réentraîner le modèle sur de vrais avis.

5. Mise en service

Les trois modèles tournent dans un seul service Python interne, appelé uniquement par l'API Node : l'application ne gère qu'une authentification, et le service ML n'est jamais exposé à Internet.

L'app ne parle qu'à l'API ; les 3 modèles vivent dans un seul service interne



architecture de mise en service · docker-compose.yml

Chaque requête de l'app passe par l'API Node, qui vérifie le jeton, appelle le service ML puis enregistre un événement dans Redis pour le Data Lake.

Modèle	Route API Node	Route du service ML	Écran mobile
A — Prix	POST /vehicles/estimate	POST /predict/vehicle-value	Estimer mon véhicule → Résultat (prix, fourchette, fiabilité)
B — Recommandation	POST /garages/recommend	POST /recommend/garages	Quel est le problème ? → Garages conseillés
C — Faux avis	POST /reviews (à la publication)	POST /moderation/review	Message après publication d'un avis

Choix techniques

- **FastAPI + Pydantic** : validation automatique des entrées (une année 3024 ou un kilométrage négatif sont refusés) et documentation interactive sur /docs.
- **Modèles chargés une seule fois au démarrage**, puis gardés en mémoire : réponse en environ 1 seconde pour la recommandation, beaucoup moins pour le prix.
- **Formats sans exécution de code** : XGBoost en binaire compressé (.ubj.gz, 42 Mo au lieu de 418 Mo en JSON), préparateur en JSON.
- **Image Docker légère** : PyTorch en version CPU et XGBoost sans dépendances GPU, soit environ 2 Go de moins.
- **Tolérance aux pannes** : si le service ML ne répond pas, l'API renvoie une erreur claire (prix, recommandation) ou publie l'avis (modération), plutôt que de bloquer l'utilisateur.
- **Tests** : 29 tests automatiques du service (15 pour A, 9 pour B, 5 pour C), plus des tests de bout en bout dans Docker et des tests sur iPhone.

6. Tests de validation du modèle C dans l'application

Les 4 scénarios ont donné le résultat attendu : seul l'avis du client venu au garage est publié et compte dans la note. Les tests ont été menés le 2 octobre 2026 sur l'API réelle (le chemin utilisé par l'application), sur le garage Boss Auto, noté 5,0 sur 2 avis importés.

Scénario	Avis publié	Décision du modèle	Raisons vues par l'administrateur
1. Auto-promotion	5★ « Le meilleur garage de Casablanca !!! », compte neuf, sans RDV	Masqué, à vérifier (score 1,000)	Aucun RDV terminé ; compte de moins de 24 h ; formulations excessives ; aucun détail concret
2. Dénigrement	1★ « Arnaque totale, des voleurs », compte neuf, sans RDV	Masqué, à vérifier (score 1,000)	Les mêmes, plus une note très éloignée de la moyenne du garage
3. Vrai client	4★ « Plaquettes changées, 600 DH comme le devis », RDV terminé	Publié immédiatement (score 0,000)	—
4. RDV annulé	4★, texte crédible et concret, RDV annulé	Masqué, à vérifier (règle métier, score 0,000)	Avis sur un RDV annulé ; compte de moins de 24 h ; 3 autres avis en 48 h

- **Note du garage** : 5,0 (2 avis) → 4,7 (3 avis) après publication, soit $(5 \times 2 + 4) / 3$. Seul l'avis du scénario 3 compte.
- **Décision de l'administrateur** : rejet des 3 avis signalés ; la note reste 4,7 sur 3 avis.
- **Message à l'auteur** : « Merci ! Votre avis sera publié après une vérification rapide. » pour les scénarios 1, 2 et 4 ; ni le score ni les raisons ne lui sont montrés.

Le scénario 4 montre que la règle métier rattrape ce que le modèle appris laisse passer : son score est de 0,000, mais l'avis porte sur un RDV annulé. Le scénario 1 a aussi été vérifié sur iPhone (message orange, avis masqué, note inchangée). Les données de test ont été supprimées ensuite.

7. Bilan et perspectives

Les trois modèles sont en service et testés dans l'application. Leur fiabilité dépend directement de la réalité des données : résultat réel pour A, en partie réel pour B, démonstration pour C.

Ce que la démarche a apporté. Plusieurs choix ont été corrigés par la mesure plutôt que fixés d'avance :

- un filtre de prix aberrants trop strict, repéré en relisant les annonces rejetées (modèle A) ;

- de faux kilométrages, repérés parce que le prix ne baissait pas avec le kilométrage (modèle A) ;
- un garage qui captait toutes les recommandations, repéré par une mesure de diversité (modèle B) ;
- des modèles appris aveugles à une fraude nouvelle, compensés par une règle métier (modèle C).

Limites communes

- Peu de données d'usage réelles : le filtrage collaboratif (B) et la détection de faux avis (C) reposent sur des simulations.
- Spécialités des garages majoritairement supposées ; notes de garages presque absentes.
- Prix de marché au niveau 2024, issus d'annonces et non de ventes.

Perspectives

1. Confirmer les spécialités des garages lors des visites terrain, puis via un formulaire dans le tableau de bord mécanicien.
2. Réentraîner le modèle C sur les décisions réelles des administrateurs, et activer le SVD (B) quand les RDV réels suffiront.
3. Réentraîner le modèle A avec des annonces récentes, et y ajouter l'historique d'entretien AUTO+ du véhicule.
4. Enrichir la base de pannes (« plaquettes », « amortisseurs »...) pour corriger les erreurs de classification restantes.
5. Enregistrer l'empreinte de l'appareil à la publication d'un avis, pour mieux détecter les faux avis sophistiqués.

Code et résultats : dossiers ml/src (modèles A, B, C), ml/service (service FastAPI), ml/notebooks et ml/reports (figures et mesures) du dépôt AUTO+ ; Pull Requests #2, #3 et #4.